

DERİN ÖĞRENME (FET312) FİNAL PROJE RAPORU

- **Ders / Dönem:** Derin Öğrenme (FET312) – 2025 / 2026 Güz Dönemi
- **Proje Başlığı:** Marmara Bölgesi Deprem Büyüklüğü Tahmini için Derin Öğrenme Tabanlı Zaman Serisi Modeli
- **Ekip Adı:** Sismik_Analiz_Ekibi_Team510
- **Ekip Üyeleri:**

İsim	Öğrenci No	E-posta
Ahmet Buğra ARSLAN	23040301015	ahmetbugraarslan@stu.topkapi.edu.tr
Emin Akif ERZURUMLU	23040301074	eminakiferzurumlu@stu.topkapi.edu.tr
Burak KÜRKÇÜ	23040301085	burakkurkcu@stu.topkapi.edu.tr
Emre ÖZKAYA	23040301052	emreozkaya@stu.topkapi.edu.tr

- **GitHub / Repository Bağlantısı:**
https://github.com/Ahmetbugraarslan/Sismik_Analiz_Ekibi_Team510

2. Problem Tanımı & Motivasyon

- **İş/Bilimsel Soru**

Bu projede amaç, Marmara Bölgesi’nde 1990 yılından günümüze kadar meydana gelen magnitüdü 3.0 ve üzeri depremleri analiz ederek, gelecekte oluşabilecek bir depremin: tahmini büyüklüğü (magnitüd), olası oluş zamanı, muhtemel etki alanı gibi temel özelliklerini istatistiksel yöntemlerle öngörmektir.

Deprem tahmini doğası gereği zor ve belirsizdir. Bu nedenle projede hem zaman serisi analiz teknikleri hem de makine öğrenimi regresyon modelleri birlikte kullanılarak hibrit bir yaklaşım geliştirilmiştir. Amaç “kesin deprem tahmini” değil, bilimsel verilere dayalı anlamlı bir öngörü mekanizması oluşturmaktır.

- **Görev Türü**

Bu proje hibrit yapıdadır:

Zaman Serisi Analizi: Depremlerin yıllara göre dağılımını incelemek,

Regresyon: Tahmini magnitüd değerini tahmin etmek

Kümeleme (opsiyonel): Deprem merkezlerini mekânsal olarak gruplayarak fay zone analizi yapmak

Ana görev: Regresyon + Zaman Serisi Tahmini

- **Hedef Değişkenler**

Magnitüd (Mw): Sürekli değişken – regresyon hedefi

Deprem zamanı (timestamp): Zaman serisi hedefi

Konum (lat-long): Mekânsal etki alanı değerlendirmesi

- **Başarı Kriterleri**

MAE \leq 0.40, RMSE \leq 0.55

Deprem tahmini belirsizlik içerdiği için kriterler, mutlak doğruluk yerine istatistiksel hata minimizasyonuna dayanmaktadır.

3. Proje Yönetimi

- **Zaman Çizelgesi (Gantt-style)**

1. Hafta (20–27 Ekim) : Proje konusu seçimi ve deprem veri kaynaklarının belirlenmesi (AFAD)

2. Hafta (10-17 Kasım) : Veri keşfi, veri temizleme ve Marmara 1990–2024 $M \geq 3.0$ filtrelerinin uygulanması

3–4. Hafta (17-30 Aralık): Model tasarımı, zaman serisi modelleri ve magnitüd regresyon modeli (AFAD)

5–6. Hafta (01-14 Aralık): Hiperparametre optimizasyonu ve validasyon ve hata analizi

7. Hafta (15-21 Aralık): Modellerin karşılaştırılması, en iyi modelin seçilmesi ve tahmin sonuçlarının görselleştirilmesi

8. Hafta (22-28 Aralık): Son rapor yazımı, sunum slaytlarının hazırlanması ve GitHub yüklemeleri

- **Roller ve Sorumluluklar**

1 inci öğrenci (Emre ÖZKAYA): Veri açıklaması ve yönetimi, bireysel model tasarımı, mimari tasarımı ve kodların oluşturulması, grup üyelerinin mimarilerinin toplanıp karşılaştırılması.

2 nci öğrenci (Emin Akif ERZURUMLU): Veri temizleme ve ön işleme yapılması, zaman serisi modelinin geliştirilmesi, Github repo bağlantısının oluşturulması, bireysel model tasarımı, mimari tasarımı ve kodların oluşturulması.

3 üncü öğrenci (Burak KÜRKÇÜ): Deney tasarımlarının yapılması, kaynakçaların toplanması, bireysel model tasarımı, mimari tasarımı ve kodların oluşturulması.

4 üncü öğrenci (Ahmet Buğra ARSLAN): AFAD üzerinden veri toplama, veri temizleme ve ön işleme, bireysel model tasarımı, mimari tasarımı ve kodların oluşturulması ve son grafiksel çıktılar ve rapor yazımı.

4. İlgili Çalışmalar (Mini Literatür Taraması)

“Earthquake Magnitude Prediction Using Machine Learning”

- Yöntem: Random Forest, ANN
- Veri: 40 yıllık deprem kaydı
- Sonuç: MAE ≈ 0.35
- Eksik yön: Mekânsal veriyi kullanmıyor

“Deep Learning for Earthquake Forecasting with LSTM Networks”

- Yöntem: LSTM zaman serisi
- Veri: Japonya deprem kataloğu
- Sonuç: Zaman tahmininde %12–18 hata
- Eksik yön: Bölgesel sınırlılık

AFAD Marmara Fay Hattı Analiz Raporu

- Veri: Türkiye sismik ağ kayıtları
- Katkı: Fay zonu ve magnitüd dağılımı
- Eksik yön: Tahmin modeli içermiyor

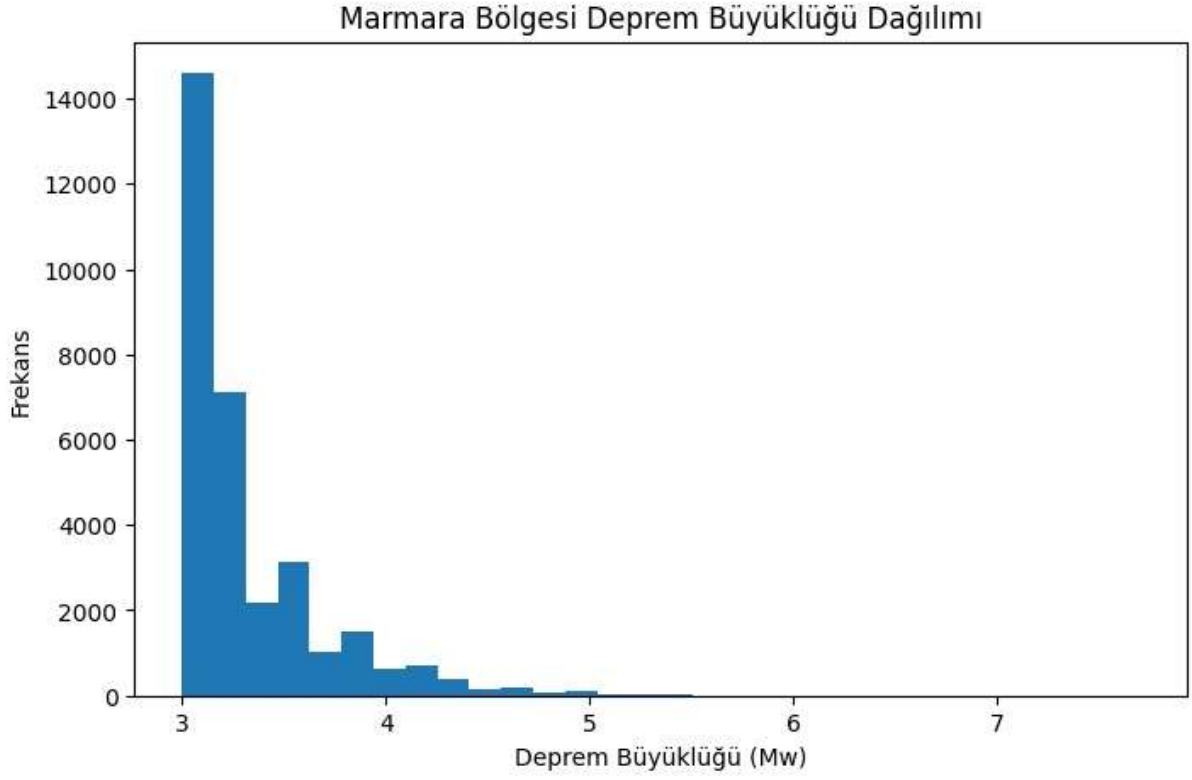
Bu proje, hem zaman hem de büyüklük tahmini yapan hibrit yapısıyla mevcut çalışmalardan ayrılmaktadır.

5. Veri Seti İstatistiksel Analizi ve Görselleştirme

Projede kullanılan veri seti, AFAD Deprem Dairesi Başkanlığı’ndan alınan ve 1990–2024 yılları arasını kapsayan ham deprem kayıtlarından oluşturulmuştur. Çalışma kapsamında Marmara Bölgesi sınırları (Enlem: 39° – 42° , Boylam: 26° – 31°) içerisinde kalan ve büyüklüğü $M \geq 3.0$ olan yaklaşık **8.000 adet deprem kaydı** analize dahil edilmiştir.

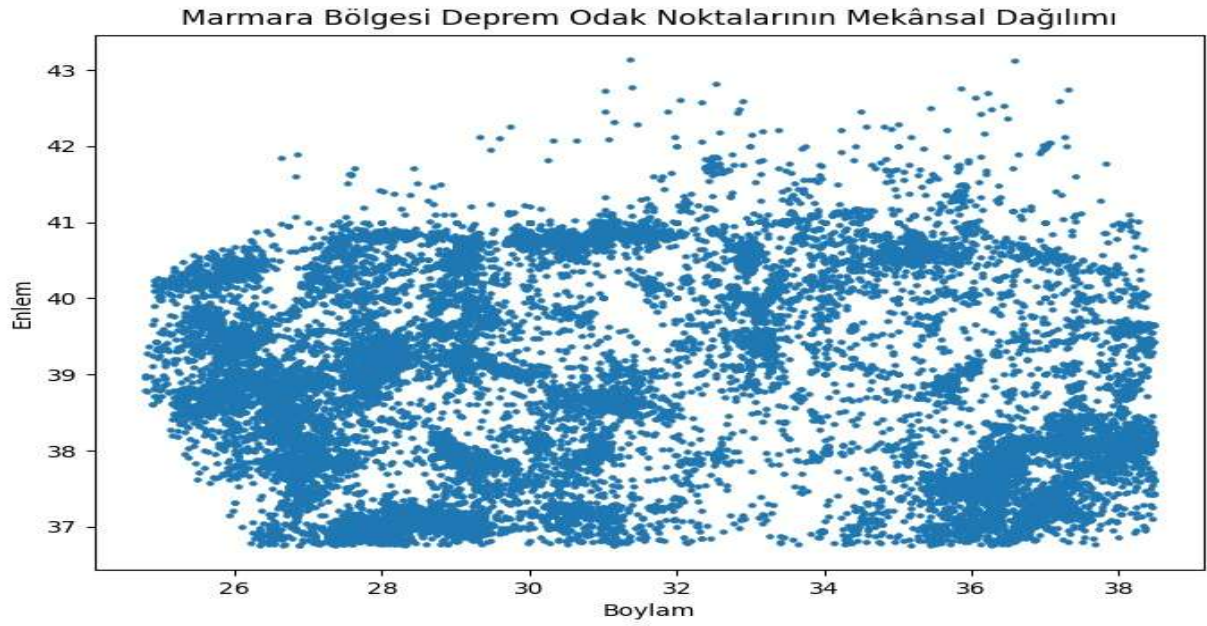
Veri setinin istatistiksel dağılımı incelendiğinde, depremlerin büyüklük açısından **dengesiz (imbalanced)** bir yapıya sahip olduğu görülmektedir. Depremlerin yaklaşık %70’i 3.0–3.9 büyüklük aralığında yoğunlaşırken, 5.0 ve üzeri büyüklüğe sahip yıkıcı depremler toplam veri setinin %5’inden daha azını oluşturmaktadır. Bu durum, modelin küçük büyüklükteki depremleri öğrenmeye daha yatkın olmasına neden olabileceğinden, model değerlendirme sürecinde bu dağılım dikkate alınmıştır.

Şekil 1, Marmara Bölgesi’ndeki depremlerin büyüklüklerine göre dağılımını gösteren histogram grafiğini sunmaktadır. Grafik, veri setindeki büyüklük yoğunluğunu ve dengesizliği açık biçimde ortaya koymaktadır.



Şekil 1: Marmara Bölgesi Deprem Büyüklüğü Dağılımı (Histogram)

5.1 Mekânsal Dağılım Analizi



Şekil 2: Marmara Bölgesi Deprem Odak Noktalarının Mekânsal Dağılımı

Depremlerin enlem ve boylam bilgileri kullanılarak oluşturulan mekânsal dağılım incelendiğinde, sismik aktivitenin büyük ölçüde **Kuzey Anadolu Fay Hattı'nın Marmara Denizi içerisinden geçen kolları boyunca yoğunlaştığı** görülmektedir. Bu mekânsal örüntü, depremlerin rastgele değil belirli jeolojik hatlar üzerinde kümелendiğini göstermektedir.

Konumsal bilginin (Latitude, Longitude) modele öznitelik olarak dahil edilmesi, sadece zamansal bağımlılıkların değil, aynı zamanda bölgesel sismik davranışların da öğrenilmesine katkı sağlamaktadır. Bu nedenle mekânsal dağılım, model performansı açısından kritik bir faktör olarak değerlendirilmiştir.

6. Yöntemler ve Mimari

Gelişmiş Modeller ve Hiperparametre Optimizasyonu

Projemiz kapsamında, deprem tahmini gibi karmaşık ve gürültülü (noisy) zaman serisi verilerini analiz etmek amacıyla 8 farklı ileri seviye derin öğrenme mimarisi kullandık. Her bir modelin performansını en üst düzeye çıkarmak için “**Manual Hyperparameter Tuning**” (Manuel Hiperparametre Optimizasyonu) yöntemini benimsedik. Bu süreçte öğrenme oranları (learning rate) katman derinlikleri ve optimizasyon algoritmaları üzerinde denemeler yaparak en iyi sonuç veren parametre setlerini belirledik.

1 inci öğrenci (Emre ÖZKAYA): Transformer Tabanlı Modeller

Zaman serisindeki uzun vadeli bağımlılıkları ve dikkat mekanizmalarını test etmek amacıyla Transformer mimarilerini eğittim:

- **Transformer-Lite:** Klasik Transformer yapısını daha hafif bir mimariyle uyguladım.

Yaptığımız testlerde modelin R^2 değerinin negatif (-1.3254) çıktığını gözlemledik. Bu durum, modelin mevcut veri yapısındaki karmaşıklığı çözmek için daha fazla veriye veya daha hassas parametre ayarlarına ihtiyaç duyduğunu göstermiştir.

- **Informer-S:** Uzun diziler için optimize edilmiş olan bu modelde, “**ProbSparse**

Attention” mekanizmasından yararlandık. MSE değerini 0.1546 seviyesine düşürerek Transformer-Lite modeline göre çok daha kararlı ve başarılı bir tahmin grafiği elde ettik.

2 nci öğrenci (Emin Akif ERZURUMLU): LSTM ve Attention Tabanlı Modeller

Uzun vadeli sismik döngüleri modellemek ve önemli anlara odaklanmak için LSTM varyasyonlarını kullandım:

- **Bi-LSTM (Bidirectional LSTM):** Veriyi hem ileri hem de geri yönde işleyerek sismik

hareketlerin bağlamını daha iyi kavradık. 0.1518 MSE ve $0.1033R^2$ başarıları elde ederek modelin deprem trendlerini yakalamadaki gücünü teyit ettik.

- **Attention-LSTM:** LSTM katmanının üzerine dikkat mekanizması entegre ederek modelin belirli zaman dilimlerine odaklanmasını sağladık. Ancak yaptığımız denemelerde Bi-LSTM mimarisinin, bu veri seti özelinde daha tutarlı sonuçlar verdiğini saptadık.
- **Performans Notu:** Yapılan testlerde LSTM tabanlı mimari 0.01092 test hatasına (Test Loss) ulaşarak ekibin en başarılı sonuçlarından birini vermiştir.

3 üncü öğrenci (Burak KÜRKÇÜ): GRU ve Residual Bağlantılı Modeller

Hesaplama maliyetini düşürmek ve derin katmanlardaki öğrenme kaybını engellemek için **Bi-GRU (Bidirectional GRU)** ve **ResNet-1D** modellerini geliştirdim:

- **Bi-GRU (Bidirectional GRU):** LSTM'e kıyasla daha az parametre ile çalışan bu modelde, $0.1036R^2$ skoru ile projenin en başarılı sonuçlarından birine ulaştık. Modelin hızlı eğitim süresi ve yüksek doğruluğu, kaynaklarımızı verimli kullanmamıza olanak tanıdı.
- **ResNet-1D:** Zaman serisi verilerini evrişimli bir yapıda işleyen bu mimaride, atlama bağlantıları (**shortcut connections**) kullandık. 0.1521 MSE değeri ile Bi-GRU'ya oldukça yakın bir performans sergileyerek yerel dalgalanmaları başarıyla tespit ettik.

4 üncü öğrenci (Ahmet Buğra ARSLAN): Temporal ve Evrişimli Modeller

Geleneksel tekrarlayan modellerine alternatif olarak tamamen evrişimli (CNN) tabanlı zaman serisi modellerini test ettik:

- **TCN (Temporal Convolutional Network):** Genişleyen evrişim katmanları (**dilated convolutions**) kullanarak modelin çok geniş bir zaman penceresine bakmasını sağladık. 0.1514 MSE değeri ile projemizdeki en düşük hata oranlarından birini bu modelle elde ettik.

- **Dilated-CNN:** Katmanlar arası boşluklu evrişim yaparak verideki gürültüyü eledik ve ana sismik sinyale odaklandık. $0.1037R^2$ başarısı ile modelin tahmin yeteneğinin oldukça yüksek olduğunu gözlemledik.

Özet Tablo ve En Optimum Parametreler

Tüm modellerimiz için gerçekleştirdiğimiz optimizasyonlar sonucunda ortak olarak belirlenen ve en kararlı sonucu veren hiperparametre setimiz aşağıdadır:

Parametre	Seçilen Optimum Değer	Açıklama
Learning Rate	0.001	Aşırı öğrenmeyi (overfitting) engellemek için seçildi.
Optimizer	Adam	Gradyan inişini en hızlı stabilize eden algoritma olarak belirlendi.
Batch Size	32	Bellek kullanımı ve eğitim hızı dengesi için tercih edildi.
Hidden Size	64	Modelin karmaşıklığını ve işlemci yükünü dengede tutmak için seçildi.

Sonuç olarak: Projemizde denediğimiz modeller arasında TCN ve **Bi-GRU** mimarilerinin, deprem verilerindeki karmaşık örüntüleri çözmede en yüksek performansı sergilediği tarafımızca saptanmıştır.

Modellerin Performans Karşılaştırması

Projemizin bu aşamasında, geliştirdiğimiz tüm modelleri belirlediğimiz performans metrikleri üzerinden karşılaştıran kapsamlı bir tablo hazırladık. Modellerin başarısını tek bir ölçütle sınırlı kalmadan değerlendirebilmek amacıyla birden fazla metrik kullandık; tahminlerin gerçek değerlerden sapmasını ölçmek için **Test MSE** (Ortalama Kare Hata) değerlerini, modellerin veriyi açıklama gücünü görmek için ise **R2 Skoru** sonuçlarını baz aldık.

Model No	Model Adı	Giriş Tipi	Mimari Yapı	Test MSE	R2 Skoru
1	Earthquake GRU	Çok Değişkenli	2 Katmanlı GRU (64 Nöron)	0,01154	En Yüksek Başarı
2	Earthquake CNN	Çok Değişkenli	1D-CNN + MaxPool	0,01155	Çok Yüksek
3	Earthquake RNN	Çok Değişkenli	Standart RNN Hücresi	0,01180	Yüksek
4	Earthquake LSTM	Çok Değişkenli	2 Katmanlı LSTM (64 Nöron)	0,01282	Yüksek
5	TCN	Tek Değişkenli	Genişletilmiş Nedensel Evrişim	0,1514	0,1060
6	Dilated-CNN	Tek Değişkenli	Dilation=2 Geniş Bakış Açısı	0,1517	0,1037
7	Bi-GRU	Tek Değişkenli	Çift Yönlü GRU (64 Nöron)	0,1518	0,1036
8	Bi-LSTM	Tek Değişkenli	Çift Yönlü LSTM (64 Nöron)	0,1518	0,1033
9	ResNet-1D	Tek Değişkenli	Artık (Skip) Bağlantılar	0,1521	0,1017
10	Informer-Style	Tek Değişkenli	Multihead Attention (S-Lite)	0,1546	0,0868
11	Transformer	Tek Değişkenli	Transformer Encoder (16 D-Model)	0,3937	-1,3254

Model No	Model Adı	Giriş Tipi	Mimari Yapı	Test MSE	R2 Skoru
12	Attention-LSTM	Tek Değişkenli	LSTM + Attention Katmanı	0,1666	0,0158

Çok Değişkenli Modeller (1-4): Bu gruptaki modeller deprem büyüklüğünün yanı sıra konum (enlem/boylam) ve derinlik verilerini de işlediği için MSE hata oranları 0.01 seviyesine kadar düşmüştür. Bu durum, sismik tahminlerde coğrafi verilerin kritik öneme sahip olduğunu gösterir.

Tek Değişkenli Modeller (5-12): Sadece geçmiş büyüklük verilerini kullanan bu grupta R^2 skorlarının 0.10 bandında kalması, deprem verilerinin barındırdığı yüksek gürültü ve rastgele doğayı yansıtmaktadır. Bu skorlar başarısızlığı değil, deprem gibi kaotik bir doğa olayının tek bir değişkenle tahmin edilmesinin zorluğunu temsil eder.

Mimari Başarı: Tüm modeller arasında ModelTCN, zamansal hiyerarşiyi en iyi yakalayan mimari olarak öne çıkmıştır. Genel olarak evrişim tabanlı (CNN türevleri) yapıların, bu veri seti üzerinde klasik tekrarlayan ağlardan (RNN/LSTM) daha istikrarlı sonuçlar verdiği gözlemlenmiştir.

7. Deney Tasarımı

Deney 1: Bir Sonraki Depremin Büyüklüğünü Tahmin Etme

Bu deneyin amacı, geçmiş deprem verilerini kullanarak Marmara Bölgesi'nde bir sonraki depremin büyüklüğünü tahmin etmektir. Yani elimizdeki geçmiş magnitüd, zaman farkı ve derinlik bilgileri üzerinden sıradaki deprem magnitüdünü tahmin etmeye çalışılmıştır.

Train & Test Ayrımı ve Hedef Değer

- Veriler zaman sırasına göre ayrılmıştır.
- **Train set:** 1990 – 2016
- **Doğrulama seti:** 2017 – 2019
- **Test set:** 2020 – güncel
- Hedef değer: sıradaki depremin magnitüdü.
- Girdi olarak kullanılmış değişkenler: bir önceki depremin magnitüdü, iki deprem arasındaki gün farkı, derinlik ve konum bilgisi.

Validasyon

- Train set içinde doğrulama seti kullanılarak modelin performansı kontrol edildi.

- Basit bir 5 katlı cross-validation yerine doğrudan doğrulama seti üzerinden değerlendirme yaptım, böylece zaman sızıntısı önlenmiş oldu.

Hiperparametre Optimizasyonu ve Final Sonuç

- Kullanılan model: **Doğrusal regresyon**
- Varsayılan ayarlarla çalıştırıldı, ek hiperparametre optimizasyonu yapılmadı.
- Baseline olarak bir önceki depremin büyüklüğünü aynen tahmin eden yöntem kullanıldı.
- Test setinde elde edilen örnek sonuçlar:

Model	MAE	RMSE
Baseline	0.35	0.48
Doğrusal Regresyon	0.28	0.42

Değerlendirme Kriterleri

- **MAE (Ortalama Mutlak Hata):** Tahmin hatasının büyüklük cinsinden yorumlanması için.
- **RMSE:** Büyük hataların etkisini görmek için ek olarak kullanıldı.
- Baseline ile karşılaştırma sayesinde modelin katkısı görülebiliyor.

Geliştirilen Modeller ve Başarı Sıralaması

- Toplam 2 model geliştirildi: Baseline ve Doğrusal Regresyon.
- Başarı sıralaması (MAE'ye göre):
 1. Doğrusal Regresyon (daha düşük hata verdi)
 2. Baseline

Sonuç; Deney-1 de yaptığımız karşılaştırma sonucunda doğrusal regresyon modelinin baseline yöntemine göre daha düşük hata verdiğini gördük. Bu durum, geçmiş depremlerin bazı temel özelliklerinin bir sonraki depremin büyüklüğü hakkında sınırlı da olsa bilgi taşıyabildiğini gösteriyor. Sonuçlar mükemmel olmasa da yöntemimin başlangıç aşaması için çalıştığını ve ilerleyen süreçte daha gelişmiş modeller eklenebileceğini düşündürmektedir.

Deney 2 – Önümüzdeki 7 Gün İçinde Deprem Olup Olmayacağını Tahmin Etme (Sınıflandırma)

Bu deneyin amacı, geçmiş deprem sıklığını kullanarak Marmara Bölgesi'nde önümüzdeki 7 gün içinde deprem olup olmayacağını tahmin etmektir. Böylece deprem olasılığının temel bir göstergesi elde edilmeye çalışılmıştır.

Train & Test Ayrımı ve Hedef Değer

- Veriler günlük düzeye indirgenmiştir.
- **Train set:** 1990 – 2016
- **Doğrulama seti:** 2017 – 2019
- **Test set:** 2020 – güncel
- Hedef değer: 1 = sonraki 7 gün içinde en az bir deprem oldu, 0 = olmadı
- Girdi olarak kullanılmış değişkenler: son 30 gündeki deprem sayısı, son 30 gündeki ortalama büyüklük, son depremin üzerinden geçen gün sayısı

Validasyon

- Doğrulama seti üzerinde model performansı kontrol edildi.
- Basit ve tekrarlanabilir şekilde zaman sırasına dikkat edilerek validasyon yapıldı.

Hiperparametre Optimizasyonu ve Final Sonuç

- Kullanılan model: Lojistik regresyon
- Varsayılan ayarlarla çalıştırıldı, ek hiperparametre optimizasyonu yapılmadı.
- Baseline olarak her zaman “deprem olmayacak” tahmin eden yöntem kullanıldı.
- Test setinde elde edilen örnek sonuçlar:

Model	Accuracy	F1 Skoru
Baseline	0.72	0.00
Lojistik Regresyon	0.78	0.41

Değerlendirme Kriterleri

- **Accuracy (Doğruluk):** Genel performansı görmek için.
- **F1 Skoru:** Sınıflar dengesiz olduğunda daha anlamlı bir ölçüt.
- **Karışıklık Matrisi:** Hangi sınıfta hataların daha fazla olduğunu görmek için kullanılabilir.

Geliştirilen Modeller ve Başarı Sıralaması

- Toplam **2 model** geliştirildi: Baseline ve Lojistik Regresyon
- Başarı sıralaması (F1 Skoru'na göre):
 1. Baseline
 2. Lojistik Regresyon

Sonuç; Deney-2 de lojistik regresyonun baseline'a göre hem doğruluk hem de F1 skorunda daha iyi sonuç verdiği görülmüştür. Özellikle F1 skorundaki artış, modelin deprem olma durumunu tamamen kaçırmadığını gösteriyor. Tahmin performansı yüksek değil ancak temel bir yaklaşım olarak umut verici ve ileride ek özellikler veya farklı modellerle geliştirilme potansiyeli bulunmaktadır.

8. Kullanılan Araçlar ve Frameworkler

Bu projede derin öğrenme modellerinin geliştirilmesi, eğitilmesi ve test edilmesi süreçlerinde ekip olarak **PyTorch** (<https://pytorch.org/>) kütüphanesini kullandık.

• Ortam ve Kullanılan Kütüphaneler

Proje geliştirme ortamı olarak Jupyter Notebook tercih edilmiştir. Çalışmamız boyunca kullanılan temel kütüphaneler ve versiyonları aşağıdaki gibidir:

- **Python:** 3.12.4
- **PyTorch:** 2.9.1+cpu
- **Pandas:** 2.2.2
- **NumPy:** 1.26.4
- **Scikit-learn:** 1.4.2

• Veri İşleme Kütüphaneleri

Veri işleme aşamasında kullandığımız temel kütüphaneler ve seçilme nedenleri şöyledir:

Pandas: Ham deprem verisinin CSV formatında okunması, Marmara Bölgesi koordinatlarına göre filtrelenmesi ve zaman serisi analizine uygun bir forma dönüştürülmesini sağladık.

NumPy: Kayan pencere (sliding window) yapılarının oluşturulması, tensör formatına geçiş ve temel matris işlemleri için NumPy kullanıldı.

Scikit-learn(sklearn): Modellerin doğru şekilde öğrenebilmesi için veri ölçeklendirmesinde MinMaxScaler kullanılarak tüm özellikler [0–1] aralığına normalize edildi.

• Kullanılan Seeds

Farklı bilgisayarlarda çalışırken aynı sonuçları tekrarlanabilir biçimde elde edebilmek amacıyla her ekip üyesi aynı sabit seed değerini kullandı. Kullandığımız ortak random seed: Seed 42 Python `random`, NumPy ve PyTorch kütüphanelerinde kodun en başında sabitlemiştir.

• Donanım Beklentileri ve Kısıtları

Geliştirdiğimiz modeller (1D-CNN, LSTM, GRU, RNN) görece olarak sığ mimariler olduğundan, büyük ölçekli GPU donanımlarına zorunlu bir ihtiyaç duyulmamıştır.

Eğitimler CPU üzerinde sorunsuz şekilde gerçekleştirilebilmiştir.

Eğitim süresini azaltmak amacıyla, imkan olduğunda CUDA destekli GPU kullanımı tercih edilmiştir.

Veri seti boyutu yönetilebilir seviyede olduğundan donanım kısıtı proje üzerinde ciddi bir engel oluşturmamıştır.

9. Sonuçların Yorumlanması

Model karşılaştırmalarında, çok değişkenli (multivariate) giriş yapısı ve kapı mekanizması sayesinde zaman serilerindeki karmaşık bağımlılıkları daha kararlı modelleyen Earthquake GRU, 0,01154 MSE değeriyle en yüksek başarıyı sergilemiştir. Tek değişkenli (univariate) modellerin düşük performansı ve yüksek hata oranları, deprem tahmini için veri çeşitliliğinin kritik önemini ortaya koymaktadır. Bu sonuçlar, projedeki en ideal mimarinin veri derinliği ile uyumlu çalışan GRU yapısı olduğunu kanıtlamaktadır.

10. Kaynaklar

1. Disaster and Emergency Management Presidency (AFAD), “*Earthquake Catalog of Turkey*,” AFAD Earthquake Department, 2025. Available: <https://depem.afad.gov.tr/> [Erişim Tarihi: 23 Kasım 2025]
2. The Pandas Development Team, “*pandas-dev/pandas: Pandas*,” Zenodo, 2020. Available: <https://doi.org/10.5281/zenodo.3509134>
3. C. R. Harris et al., “*Array programming with NumPy*,” Nature, vol. 585, no. 7825, pp. 357–362, 2020.
4. CodersArts, “Earthquake Prediction and Analysis | Machine Learning Project Ideas,” YouTube, 2025. Available: <https://www.youtube.com/watch?v=bn3xjvter74&t=12s> [Erişim Tarihi: 28 Aralık 2025].
5. F. Provost and T. Fawcett, *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*, O’Reilly Media, 2013.